Обучение с учителем

Санкт-Петербургский государственный университет
Кафедра статистического моделирования

16 сентября 2025, Санкт-Петербург

Введение

Машинное обучение — это раздел искусственного интеллекта, в котором разрабатываются методы и алгоритмы, позволяющие компьютерам обнаруживать закономерности в данных и делать прогнозы без явных инструкций.

Обучение с учителем — один из способов машинного обучения, в ходе которого для каждого примера в обучающем наборе известно, какой результат является правильным.

Пример задач:

- Регрессия: предсказание стоимости недвижимости, количества продаж некоторого товара, погоды.
- Классификация: предсказание ценовой категории товара, типа изображения, болеет ли человек или нет.

Постановка задачи

Дано:

1. Пространство объектов X — множество описаний объектов (например, фотографии, тексты, таблицы с признаками).
2. Пространство ответов Y — множество меток или значений, которые нужно предсказывать (например, классы «кот»/«собака» или числовые значения цен).
3. Обучающая выборка $D = \{(x_i, y_i)\}_{i=1}^{n}$, где
   - $x_i \in X$ — набор значений признаков (регрессоров).
   - $y_i \in Y$ — целевая переменная или метка, которую мы хотим научиться предсказывать.
   - n — количество индивидов (записей) в выборке.

Задача: построить такую функцию (модель)

$$a : X \longrightarrow Y,$$

чтобы ее предсказания $\hat{y} = a(x)$ были как можно ближе к истинным ответам y.

Функция потерь

Чтобы оценить, насколько хорошо модель предсказывает ответы, используется **функция потерь** $L(y, \hat{y})$. Она показывает, насколько велико расхождение между истинными значениями y и его предсказаниями $\hat{y}$.

Примеры:

- Для задачи **регрессии** наиболее распространенной функцией потерь является среднеквадратичная ошибка (MSE):

$$L(y, \hat{y}) = \frac{1}{n} \sum_{i=1}^{n} (y_i - \hat{y}_i)^2.$$

- Для задачи **бинарной классификации**, если $\hat{y}$ представляет собой вектор вероятностей принадлежности к положительному классу, используется кросс-энтропия:

$$L(y, \hat{y}) = -\sum_{i=1}^{n} \left[y_i \ln \hat{y}_i + (1 - y_i) \ln(1 - \hat{y}_i) \right].$$

Линейная классификация

Пусть целевая переменная y принимает значения $\{-1, 1\}$. Хотим обучить линейную модель так, чтобы плоскость, которую она задает, как можно лучше отделяла объекты одного класса от другого.

Линейный классификатор:

$$\hat{y} = a(x; w) = \text{sign}\langle x, w\rangle.$$

Функция потерь:

$$L(y, \hat{y}) = \sum_{i=1}^{n} \mathbb{I}[y_i \langle x_i, w\rangle < 0] \longrightarrow \min_w .$$

Линейная классификация. Отступ

Величина $M_i = y_i \langle x_i, w \rangle$ называется **отступом** (margin) классификатора. Абсолютная величина отступа говорит о степени уверенности классификатора.

Проблема: функция $\mathbb{I}[M < 0]$ кусочно-постоянная, следовательно функцию потерь невозможно оптимизировать градиентными методами, поскольку во всех точках производная равна нулю.

Решение: можно мажорировать эту функцию более гладкой функцией и минимизировать функцию потерь с этой мажорирующей функцией.

Линейная классификация. Функции потерь

1. Перцептрон: $L(M) = \max(0, -M)$ — отступы учитываются только для неправильно классифицированных объектах пропорционально величине отступа.
2. Hinge (SVM): $L(M) = \max(0, 1 - M)$ — объекты, которые классифицированы правильно, но не очень «уверенно», продолжают вносить свой вклад в градиент.
3. Логистическая: $L(M) = \ln\left(1 + e^{-M}\right)$.

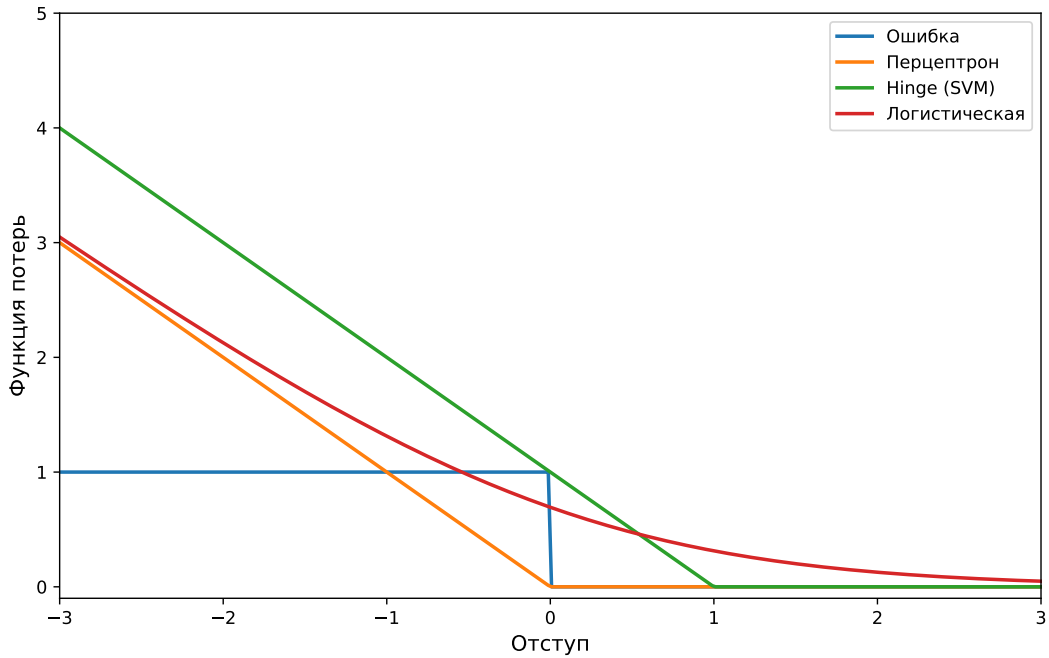

Логистическая регрессия

Рассмотрим задачу классификации как на задачу предсказания вероятностей (например, предсказание «кликабельности» рекламного баннера).

Принцип работы: научить линейную модель предсказывать значения $z \in \mathbb{R}$ (логиты), а затем преобразовывать их в вероятности с помощью сигмоиды:

$$z_i = \langle x_i, w \rangle = \ln \frac{p_i}{1 - p_i}, \quad p_i = \frac{1}{1 + e^{-\langle x_i, w \rangle}} = \sigma(\langle x_i, w \rangle).$$

Функция правдоподобия для распределения Бернулли:

$$p(y \mid \mathbf{X}, w) = \prod_{i=1}^{n} p_i^{y_i} (1 - p_i)^{1 - y_i}.$$

Прологарифмируем:

$$\sum_{i=1}^{n} \Big[y_i \ln(\sigma(\langle x_i, w \rangle)) + (1 - y_i) \ln(1 - \sigma(\langle x_i, w \rangle)) \Big].$$

Логистическая регрессия. Связь с отступом

Теперь пусть $y \in \{-1, 1\}$. Тогда, поскольку $\sigma(z) = 1 - \sigma(-z)$, логарифм правдоподобия можно представить в следующем виде:

$$\begin{aligned}\ln p(y \mid \mathbf{X}, w) &= -\sum_{i=1}^{n} \Big[\mathbb{I}[y_i = 1]\sigma(z_i) + \mathbb{I}[y_i = -1]\,(1 - \sigma(z_i))\Big] \\ &= -\sum_{i=1}^{n} \ln \sigma(y_i \langle x_i, w\rangle) \\ &= \sum_{i=1}^{n} \ln\left(1 + e^{-M}\right)\end{aligned}$$

Таким образом, функцию потерь в логистической регрессии можно представить в виде функции от отступа.